深度学习课程实验报告

Course Project Report

面向跨受试者运动想象识别的 xxx多模态深度学习研究

从可解释经典基线到可靠性门控融合

课程名称：	深度学习
学生姓名：	xxx
学　　号：	xxx
数据集：	Shin2017A，同步 EEG–fNIRS，xxx 名受试者
任务：	左/右手运动想象二分类
完成日期：	xxx

摘　要

运动想象脑机接口需要在低信噪比、强个体差异条件下稳定识别用户意图。EEG 具有毫秒级时间分辨率，但易受噪声和跨人分布漂移影响；fNIRS 描述 HbO/HbR 血氧动力学，提供互补信息，却存在响应延迟与通道质量差异。针对前期经典融合实验中“受试者内略有提升、跨 Session 未形成稳定收益”的现象，本研究进一步构建 EEGNet-like、fNIRS-CNN、双编码器拼接融合和可靠性门控融合四类轻量深度模型，并保留 CSP+sLDA 与 CSP+fNIRS+sLDA 两类可解释基线。

实验使用 Shin2017A 全部 xxx 名受试者、xxx 条同步试次。主评估采用受试者独立的分层分组五折：测试受试者在训练与模型选择阶段完全不可见，验证集也由完整受试者组成；所有归一化统计量仅由内层训练受试者拟合。训练使用 AdamW、交叉熵、余弦退火和早停，并保存逐试次 out-of-fold 预测、逐轮学习曲线、折级配置、受试者级指标与模型检查点。

结果显示，受试者独立条件下总体最优模型为 EEGNet-like，受试者平均准确率为 xxx ；深度模型中最优者为 EEGNet-like（xxx ）。EEGNet-like 的受试者平均准确率为 xxx ，而可靠性门控融合为 xxx ；门控相对 EEGNet 的受试者平均差异为 -xxx ，xxx 人中胜/平/负为 8/1/xxx。该结果表明：轻量时空卷积能够在严格跨人协议中学习有效表示，但统一门控尚未自动转化为稳定的个体级融合收益。研究的核心价值不在于追求单一最高分，而在于形成一条可复现、可审计、可扩展到质量感知与跨数据集泛化的多模态深度学习实验链路。针对负结果，报告进一步给出质量向量、复合损失、递增消融矩阵、统计成功判据和跨数据集两阶段验证方案，使“扩展方向”转化为可执行、可证伪的后续实验设计。

关键词： EEG；fNIRS；运动想象；多模态深度学习；EEGNet；门控融合；跨受试者泛化

目录

结论先行 **4**

1 研究背景与问题定义 **4**

1.1 为什么研究 EEG–fNIRS 融合 4

1.2 从经典实验暴露的问题出发 4

1.3 研究假设 5

1.4 研究假设与证据闭环 5

2 相关工作 **6**

2.1 EEG 深度解码 6

2.2 多模态融合与门控 6

2.3 EEG–fNIRS 数据与融合研究 6

3 数据集与预处理 **6**

3.1 数据规模与对齐 6

3.2 EEG 预处理 6

3.3 fNIRS 预处理 7

3.4 数据质量与可追溯性 7

4 方法 **8**

4.1 经典基线 8

4.2 EEGNet-like 编码器 8

4.3 fNIRS-CNN 编码器 8

4.4 拼接融合与可靠性门控 8

4.5 损失函数与优化 8

5 实验设计 **9**

5.1 三层防泄漏划分 9

5.2 评价指标与统计分析 9

5.3 复现环境 10

6 实验结果 **10**

6.1 阶段 A：经典融合基线 10

6.2 阶段 B：受试者独立深度学习主结果 11

6.3 折间稳定性 11

6.4 融合增益与受试者异质性 13

6.5 门控是否真的表示模态可靠性 13

6.6 错误结构与训练动态 13

7 讨论 **16**
7.1 深度学习带来了什么 16
7.2 为什么融合没有稳定超过 EEGNet 16
7.3 与文献结果的关系 17
7.4 失败分析的课程价值 17

8 从扩展方向到可执行深化实验 **17**
8.1 尚未闭合的问题与深化目标 17
8.2 质量感知门控的可实现定义 17
8.3 消融矩阵与公平比较 18
8.4 统计口径与预注册成功判据 18
8.5 外部验证的边界与两阶段方案 19
8.6 课程知识点与产出映射 19

9 局限性、伦理与有效性威胁 **20**
9.1 局限性 20
9.2 有效性威胁控制 20
9.3 伦理说明 20

A 复现实验命令 21

B 核心产物索引 21

C 报告证据口径 21

结论先行

在完全未见受试者的严格评估中，深度模型确实学到了优于随机水平的跨人表示；但“增加 fNIRS 并学习一个门”并不等于自动获得稳定融合收益。

本项目从“模型是否能在同一个人的随机划分上取得较高分”推进到“模型能否服务于新用户”。前者适合评估个体校准后的识别能力，后者才接近免校准部署。为此，本轮实验将所有 xxx 名受试者纳入五折外层测试，并把模型选择所用验证集也设置为受试者级隔离。这一协议比普通随机划分更难，却能显著降低受试者身份、基线幅值和固定通道模式泄漏到测试集的风险。

本轮形成五项可核验成果：

1. **真实深度学习实验。**对原始 EEG 时序和 HbO/HbR 时序分别训练轻量卷积编码器，并比较单模态、拼接融合和门控融合；
2. **统一的公平对照。**经典 CSP+sLDA、经典特征融合与深度模型使用同一外层受试者划分，避免不同论文或不同协议之间的数字错位；
3. **超越平均值的分析。**同时报告 bootstrap 置信区间、xxx 人胜/平/负、Wilcoxon 配对检验、折间波动、混淆矩阵、训练曲线和门控可解释性；
4. **可复现交付。**代码、随机种子、拆分受试者、逐试次预测、模型参数、训练时长、环境版本、检查点和验收报告均保存在项目目录；
5. **可执行深化方案。**将质量感知、模态缺失鲁棒性、跨人域对齐和外部验证拆成递增消融，并预先规定成功、失败与停止条件。

1 研究背景与问题定义

1.1 为什么研究 EEG–fNIRS 融合

运动想象脑机接口通过识别用户想象左手或右手运动时的脑活动，将神经信号转化为外部控制指令。EEG 直接记录头皮电位，采样快、设备成熟，是运动想象识别的主流模态；但其空间混叠严重、信噪比较低，且跨受试者差异显著。fNIRS 通过近红外光估计氧合血红蛋白（HbO）与脱氧血红蛋白（HbR）的变化，能够从血氧动力学角度补充脑区活动，但响应较慢、对探头接触和生理噪声敏感。

Fazli 等在同步 NIRS–EEG 研究中证明，两个模态具有真实的生理互补性，并在受试者内实验中获得总体性能改善 [1]。Shin 等随后公开了单试次同步 EEG+NIRS 数据，为统一协议下的多模态比较提供了基础 [2]。然而，“模态互补”是一个信息层面的命题，并不自动推出“任何融合模型都更好”。融合模型还必须解决表示尺度不一致、样本量有限、跨人漂移和弱模态拖累等问题。

1.2 从经典实验暴露的问题出发

前序实验使用 xxx 人数据比较了 EEG-only、fNIRS-only、特征级早期融合和嵌套分数级融合。在受试者内重复五折中，EEG-only 为 xxx ，嵌套融合为 xxx ；但留一 Session 时 EEG-only

为 xxx ，嵌套融合下降到 xxx 。这个结果提示：固定融合器能够利用同分布校准数据中的互补信息，却难以抵抗时段漂移。

本轮进一步提出一个更严格的问题：

> 在测试受试者完全不可见、归一化与早停也不接触测试人的条件下，轻量深度表示能否超过可解释经典基线？可靠性门控能否根据不同人的模态质量，自适应抑制较弱模态？

1.3 研究假设

H1：深度 EEG 表示有效。
EEGNet-like 在跨受试者协议中应不弱于 CSP+sLDA，因为时域卷积和深度可分离空间卷积可以共同建模节律与通道组合。

H2：fNIRS 单模态可提供弱但非随机信息。
fNIRS-CNN 应能从 HbO/HbR 时序中学习血氧响应，但其表现可能低于 EEG 分支。

H3：无条件拼接不保证提升。
双编码器拼接增加了参数和模态交互，但在 xxx 条试次规模下可能受到过拟合影响。

H4：门控只在“学会可靠性”时有效。
若门控权重确实随 EEG 与 fNIRS 的受试者级性能差异变化，门控融合才可能稳定优于 EEGNet；否则门只是额外自由度。

1.4 研究假设与证据闭环

为避免“提出假设、只汇报最高分”的松散结构，表 1 把每个假设与对应对照、观察量和当前判定逐一对应。这里的“支持”仅表示在当前 Shin2017A 协议下获得相符证据，不外推为普遍结论。

表 1 研究假设、实验观察与判定的对应关系

假设	核心对照	关键观察	当前判定
H1	EEGNet-like vs CSP+sLDA	xxx % vs xxx %，平均差 +xxx pp，配对检验未显著	方向支持，但证据不足以声称稳定优越
H2	fNIRS-CNN vs 随机水平	受试者均值 xxx %，xxx% CI 为 xxx %–xxx %	支持“弱但非随机”，同时确认其跨人稳定性有限
H3	拼接融合 vs EEGNet-like	xxx % vs xxx %，平均差 −xxx pp	支持：无条件增加模态与参数并不保证收益
H4	门控融合 vs EEGNet-like	平均差 −xxx pp；门权重与单模态优势 $\rho = -$xxx	未满足：当前门控没有学成可靠性传感器

2 相关工作

2.1 EEG 深度解码

Roy 等对 xxx –xxx 年 EEG 深度学习研究进行了系统综述，指出卷积网络是最常见的架构，同时强调数据规模、评估协议和复现信息不足会显著影响结论可信度 [3]。Lawhern 等提出 EEGNet，用时间卷积学习频率滤波器、用深度卷积学习通道空间滤波器，再以可分离卷积控制参数量；该结构特别适合小样本 BCI 任务 [4]。因此，本项目并未堆叠大型 Transformer，而是选择与数据规模相匹配的 EEGNet-like 编码器。

2.2 多模态融合与门控

多模态机器学习通常把融合划分为早期、联合表示和决策级等路径，其难点不仅是对齐，还包括不同模态的噪声、缺失和信息不平衡 [5]。Arevalo 等提出门控多模态单元，以乘性门控制各模态对联合表示的贡献 [6]。本项目采用与之相近的思想，但把门控解释限定为“样本级表示权重”，并通过受试者级相关分析检验它是否真的反映可靠性。进一步看，ModDrop 通过训练阶段随机移除模态来提高缺失或受污染输入下的鲁棒性 [7]；QMF 与不确定性融合研究则强调，动态权重只有与单模态泛化误差或不确定性建立正确关系，才有机会稳定优于静态融合 [8, 9]。这为本文门控失败后的深化方案提供了直接方法依据，而不是简单更换更大的网络。

2.3 EEG–fNIRS 数据与融合研究

Shin2017A 包含 xxx 名受试者的同步 EEG 与 NIRS 单试次数据，是当前任务的主要数据源 [2]。Li 等在同一数据上比较融合阶段，报告早期融合 Y 形网络能够优于若干中期和晚期融合配置 [10]。但不同工作在时间窗、预处理、受试者内/跨受试者拆分和汇总方式上并不完全一致，因此本报告只把文献结果作为方法动机，不把异协议数字直接当作本实验的横向排名。Yi 等 xxx 年发布的多关节 EEG–fNIRS 数据集提供了 xxx 条试次，可作为未来跨数据集迁移的外部验证场景 [11]。

3 数据集与预处理

3.1 数据规模与对齐

实验使用 Shin2017A 全部 xxx 名受试者。每人包含 3 个运动想象 Session，每个 Session 包含 xxx 条左手和 xxx 条右手试次，因此：

$$\text{xxx subjects} \times 3 \text{ sessions} \times \text{xxx trials} = 1,\text{xxx aligned trials}.$$

每名受试者恰有 xxx 条左手和 xxx 条右手试次，类别完全平衡。EEG 与 fNIRS 通过 subject、session、trial 三个键逐项核对后才写入统一缓存，从数据源头避免错配。

3.2 EEG 预处理

EEG 分支选择可稳定匹配的 xxx 个运动/顶叶通道，执行公共平均参考、8–xxx Hz 四阶 Butterworth 零相位带通，并截取提示后 xxx–xxx s。经典基线在每一外层训练折重新拟合 4 分量、

表 2 同步多模态输入的形状与用途

模态	通道	时间点	单试次形状	用途
EEG	xxx	xxx	xxx × xxx	经典 CSP 与 EEGNet-like 原始时序输入
fNIRS-HbO	xxx	xxx	xxx × xxx	fNIRS-CNN 血氧时序输入
fNIRS-HbR	xxx	xxx	xxx × xxx	与 HbO 堆叠为 xxx 通道输入
fNIRS 统计特征	xxx	–	xxx	经典特征融合基线

Ledoit–Wolf 正则化 CSP；深度分支则对每个通道使用内层训练受试者估计均值和标准差，不使用验证或测试受试者统计量。

3.3 fNIRS 预处理

fNIRS 使用 xxx/xxx nm 光强，依据修正 Beer–Lambert 定律估计 HbO/HbR；选择 xxx 个双侧运动区通道，进行 xxx –xxx Hz 零相位带通，截取 −3–xxx s 并以 −3–0 s 作为基线。经典分支在 2–xxx s 提取每通道 HbO/HbR 的均值与斜率，共 xxx 维；深度分支直接把 xxx 通道 HbO 与 xxx 通道 HbR 堆叠为 xxx × xxx 时序。

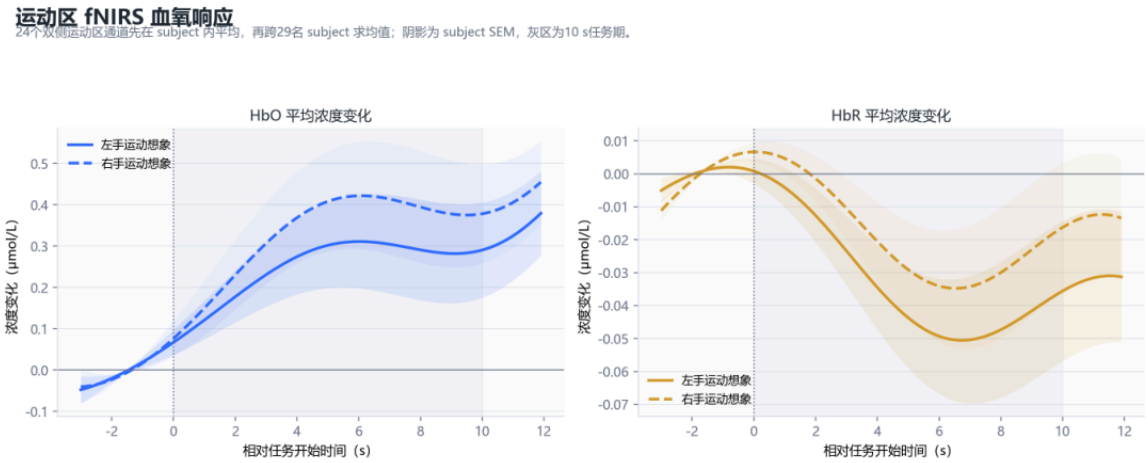


图 1 xxx 名受试者运动区 HbO/HbR 平均响应。阴影为受试者级标准误，用于核对基线、响应平滑性与血氧延迟，不作为分类显著性检验。

3.4 数据质量与可追溯性

项目保存官方压缩包大小、SHA256、解压清单、xxx 人预处理缓存和逐试次标签统计。验收脚本逐人检查 xxx 条试次、左右手平衡、3 个 Session、有限数值和多模态键一致性。这一层把“代码能跑”与“xxx 人数据确实全部进入实验”区分开来。

4 方法

4.1 经典基线

B1. CSP+sLDA：在外层训练受试者上拟合正则化 CSP，将 4 个对数方差特征输入标准化与收缩 LDA；

B2. CSP+fNIRS+sLDA：拼接 4 维 CSP 与 xxx 维 fNIRS 统计特征，再训练标准化收缩 LDA。

这两个模型与深度模型使用相同的外层测试受试者，因此能够回答“深度表示是否在同一泛化难度下超过经典方法”，而不是比较不一致协议下的数字。

4.2 EEGNet-like 编码器

EEG 编码器先以 $1 \times$ xxx 时间卷积学习频率选择，再以跨 xxx 通道的深度卷积学习空间滤波；随后使用深度可分离时间卷积、平均池化、ELU 和 Dropout，最终投影到 xxx 维嵌入 $\mathbf{z}_e$。与全连接大网络相比，深度卷积和可分离卷积显著减少参数，符合 EEGNet 的小样本设计原则 [4]。

4.3 fNIRS-CNN 编码器

fNIRS 编码器输入 xxx $\times$ xxx 的 HbO/HbR 序列，依次采用核长 9、7、5 的一维卷积、批归一化、ELU、平均池化与 Dropout，并通过自适应平均池化得到 xxx 维嵌入 $\mathbf{z}_f$。较长卷积核用于覆盖缓慢血氧变化，池化用于降低局部高频扰动。

4.4 拼接融合与可靠性门控

拼接融合直接构造

$$\mathbf{z}_c = [\mathbf{z}_e; \mathbf{z}_f], \qquad \hat{\mathbf{y}} = \mathrm{MLP}(\mathbf{z}_c).$$

门控融合先由两个模态的联合表示估计 EEG 权重：

$$g = \sigma\left(\mathbf{W}_2\ \mathrm{ELU}\left(\mathbf{W}_1[\mathbf{z}_e; \mathbf{z}_f]\right)\right),$$

$$\mathbf{z}_g = g\mathbf{z}_e + (1-g)\mathbf{z}_f, \qquad \hat{\mathbf{y}} = \mathrm{MLP}(\mathbf{z}_g).$$

其中 $g \in [0,1]$；g 越大表示当前样本更偏向 EEG。模型并未预先规定 EEG 必须更强，而是通过分类损失学习权重。为了避免把门控图形当作因果解释，本项目只检验受试者平均 g 是否与“EEGNet 准确率减 fNIRS-CNN 准确率”同向变化。

4.5 损失函数与优化

所有深度模型使用二分类交叉熵：

$$\mathcal{L}_{\mathrm{CE}} = -\frac{1}{N}\sum_{i=1}^{N}\sum_{c\in\{\mathrm{xxx}\}} y_{ic}\log p_{ic}.$$

优化器为 AdamW[12]，初始学习率 xxx^{-3}，权重衰减 xxx^{-3}，余弦退火至初始学习率的 1/xxx。梯度范数裁剪为 5，批量大小 xxx，Dropout 为 xxx，最多训练 xxx 轮；至少训练 xxx 轮后，若验证 Macro-F1 连续 8 轮未改善则早停。

表 3 四类深度模型的结构角色

模型	输入与融合	主要问题
EEGNet-like	EEG 原始时序，单编码器	深度 EEG 表示能否超过 CSP
fNIRS-CNN	HbO/HbR 原始时序，单编码器	血氧时序是否含跨人判别信息
双编码器拼接	$[\mathbf{z}_e; \mathbf{z}_f]$	联合表示是否优于 EEG 单模态
可靠性门控	$g\mathbf{z}_e + (1-g)\mathbf{z}_f$	自适应权重能否抑制弱模态

5 实验设计

5.1 三层防泄漏划分

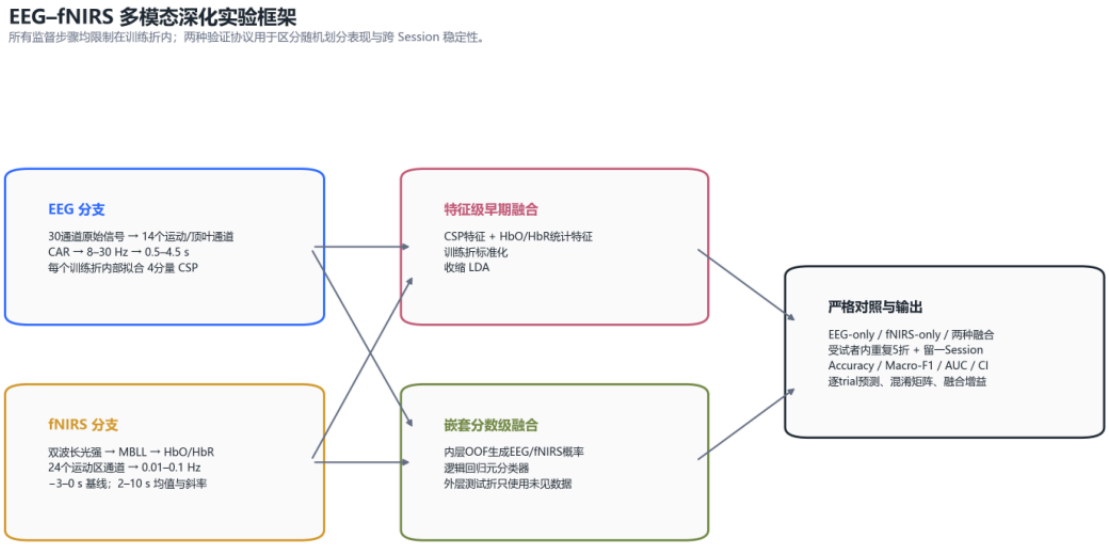


图 2 从同步数据、折内预处理到多模型比较的总体实验框架。深度阶段在此基础上进一步采用受试者独立外层五折和受试者独立验证集。

主评估采用 5 折 StratifiedGroupKFold，group 为 subject。每个外层折约留出 5–6 名完整受试者做测试；其余受试者中再划出约 xxx% 的完整受试者做验证，用于早停与最佳轮次选择。数据流遵守：

$$\text{inner-train subjects} \longrightarrow \{\text{normalization, training}\} \longrightarrow \text{validation subjects} \longrightarrow \text{test subjects}.$$

测试受试者不参与归一化、CSP、早停或阈值选择。由于每名受试者类别平衡，按受试者分组不会破坏总体二分类平衡。所有模型共享同一外层拆分，受试者级配对比较具有明确对应关系。

5.2 评价指标与统计分析

- **主指标**：先计算每名测试受试者 Accuracy，再对 xxx 人求均值；

- **区间**：以 subject 为重采样单位，bootstrap xxx 次得到 xxx% CI；
- **辅助指标**：trial-level Accuracy、Balanced Accuracy、Macro-F1、ROC-AUC；
- **配对比较**：对 xxx 人准确率差使用双侧 Wilcoxon 符号秩检验，同时报告胜/平/负和配对效应量 Cohen's d_z；
- **可解释性**：分析门控权重与单模态性能差的 Spearman 相关，并呈现每个受试者的融合增益。

所有统计检验均为探索性分析，未做多重比较校正，因此 p 值只用于定位现象，不用于宣称临床级显著性。

5.3 复现环境

本轮正式实验在 Windows 本机项目虚拟环境执行，Python xxx、PyTorch xxx CPU 构 xxx
六模型五折总训练用时约 xxx 分钟；每个深度检查点同时保存模型配置、归一化统计量、受试者拆分、最佳轮次与随机种子。

6 实验结果

6.1 阶段 A：经典融合基线

表 4 前序经典融合实验结果（xxx 名受试者）

验证协议	模型	Accuracy	xxx% CI	Macro-F1
受试者内重复 5 折	EEG-only	xxx	[xxx , xxx]	xxx
受试者内重复 5 折	fNIRS-only	xxx	[xxx , xxx]	xxx
受试者内重复 5 折	特征级早期融合	xxx	[xxx , xxx]	xxx
受试者内重复 5 折	嵌套分数级融合	xxx	[xxx , xxx]	xxx
留一 Session 验证	EEG-only	xxx	[xxx , xxx]	xxx
留一 Session 验证	fNIRS-only	xxx	[xxx , xxx]	xxx
留一 Session 验证	特征级早期融合	xxx	[xxx , xxx]	xxx
留一 Session 验证	嵌套分数级融合	xxx	[xxx , xxx]	xxx

受试者内重复五折中，嵌套分数级融合由 EEG-only 的 xxx 提高到 xxx ；但留一 Session 时，融合由 EEG-only 的 xxx 下降到 xxx 。经典结果说明 fNIRS 并非完全无信息，但统一融合策略对分布漂移敏感。这一观察直接推动本轮门控模型和更严格跨人协议。

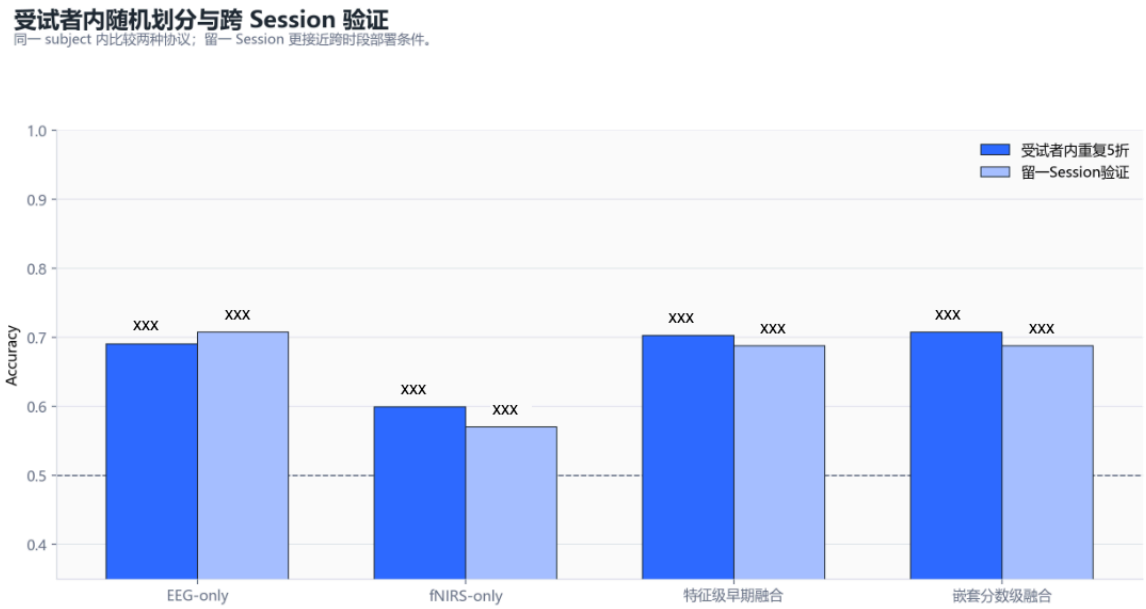


图 3 经典模型在受试者内重复五折与留一 Session 协议下的表现差异。同一模型的结论会随部署假设改变。

6.2 阶段 B：受试者独立深度学习主结果

表 5 受试者独立五折评估结果（xxx 名受试者）

模型	参数量	Subject Acc.	xxx% CI	Macro-F1	折均训练时长/s
CSP+sLDA	–	xxx	[xxx , xxx]	xxx	xxx
CSP+fNIRS+sLDA	–	xxx	[xxx , xxx]	xxx	xxx
EEGNet-like	xxx k	xxx	[xxx , xxx]	xxx	xxx
fNIRS-CNN	xxx k	xxx	[xxx , xxx]	xxx	xxx
双编码器拼接融合	xxx k	xxx	[xxx , xxx]	xxx	xxx
可靠性门控融合	xxx k	xxx	[xxx , xxx]	xxx	xxx

总体最优模型为 EEGNet-like（xxx ）；在四类深度模型中，EEGNet-like 最优（xxx ）。EEGNet-like 达到 xxx ，明显高于 fNIRS-CNN 的 xxx ，支持 H1 与 H2 的“EEG 主导、fNIRS 较弱但非完全随机”判断。拼接融合为 xxx ，门控融合为 xxx ；二者均未形成对 EEGNet 的稳定替代，说明增加模态和参数并不能抵消跨人漂移。

6.3 折间稳定性

EEGNet 与融合模型在若干折中的排序发生反转，表明模型优劣受测试受试者组成影响。这种波动不是“坏结果”，而是跨人部署风险的直接量化。若只挑选表现最好的一折，会系统性高估模型泛化能力。

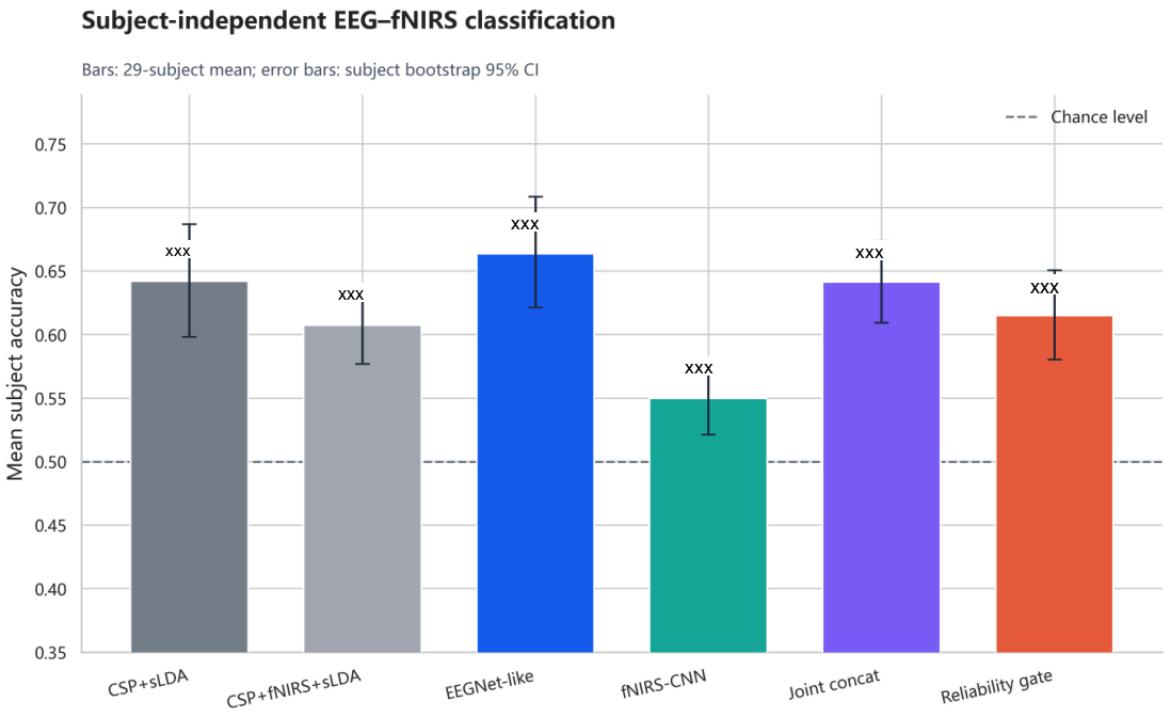


图 4 六类模型在受试者独立五折中的受试者平均准确率与 bootstrap xxx% CI。

表 6 各外层折测试准确率

模型	Fold 1	Fold 2	Fold 3	Fold 4	Fold 5
CSP+sLDA	xxx	xxx	xxx	xxx	xxx
CSP+fNIRS+sLDA	xxx	xxx	xxx	xxx	xxx
EEGNet-like	xxx	xxx	xxx	xxx	xxx
fNIRS-CNN	xxx	xxx	xxx	xxx	xxx
双编码器拼接融合	xxx	xxx	xxx	xxx	xxx
可靠性门控融合	xxx	xxx	xxx	xxx	xxx

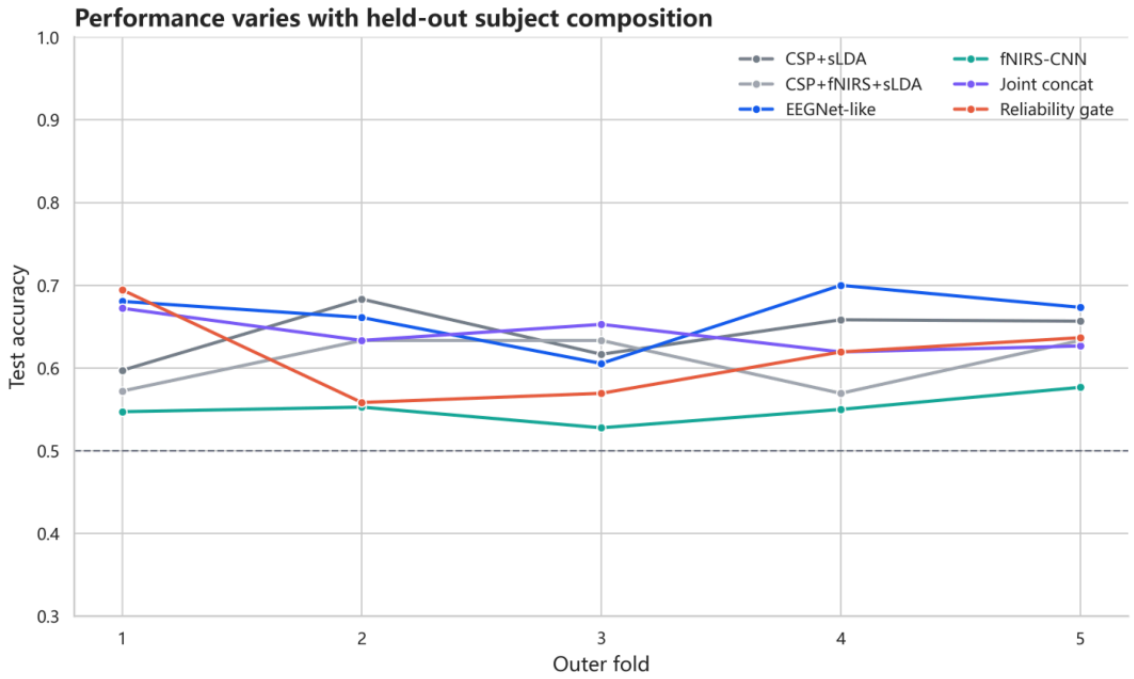


图 5 不同外层测试受试者组合下的折级准确率。折间波动反映真实的个体异质性，也是不能只报告单一划分的原因。

6.4 融合增益与受试者异质性

门控融合相对 EEGNet 的平均差异为 -xxx ，胜/平/负为 8/1/xxx，Wilcoxon $p =$ xxx ；拼接融合相对 EEGNet 的平均差异为 -xxx 。结果支持 H3：无条件拼接未形成稳定收益。对于 H4，门控在部分受试者上有效，但整体尚未达到“可靠性自适应”的目标。

6.5 门控是否真的表示模态可靠性

门控的全体试次平均 EEG 权重为 xxx 。若门控完全学会模态可靠性，“EEGNet 准确率减 fNIRS-CNN 准确率”越大，平均 g 应越高，同时融合增益不应系统性为负。图 7 显示这种关系并不充分稳定，说明当前门控更可能同时吸收类别模式、训练折偏差和表示尺度，而非纯粹的信号质量。这也是门控需要显式质量监督或不确定性约束的证据。

6.6 错误结构与训练动态

左右手类别完全平衡，因此总体准确率不受类频率偏置驱动。混淆矩阵用于检查模型是否系统性偏向某一只手；Macro-F1 与 Accuracy 排序基本一致时，可排除“仅靠单类预测抬高准确率”的解释。

训练曲线显示，联合模型能够继续降低训练损失，却不总能同步提高受试者独立验证 Macro-F1。早停因此不是装饰性设置，而是限制多模态模型利用个体特征过拟合的关键环节。fNIRS-CNN 较早进入平台期，也与其单模态跨人判别力较弱相一致。

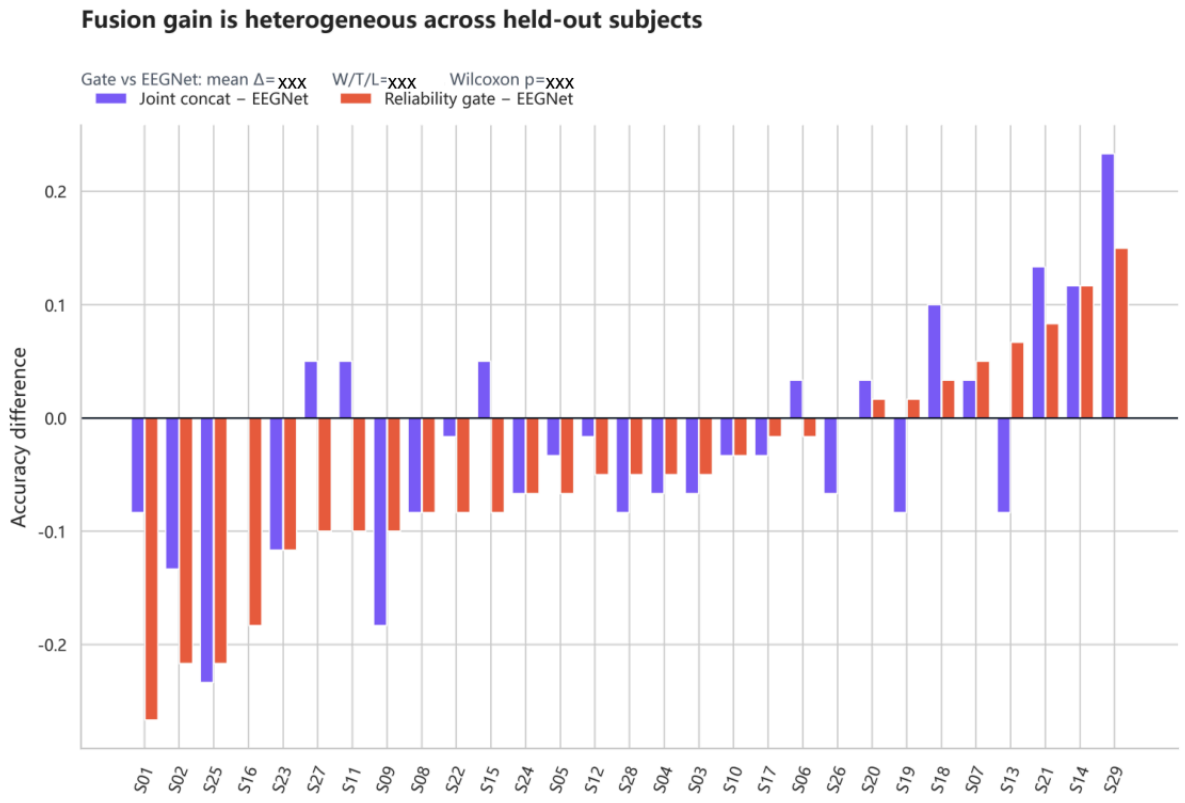


图 6 拼接融合和门控融合相对 EEGNet 的逐受试者准确率差。正值表示融合改善。

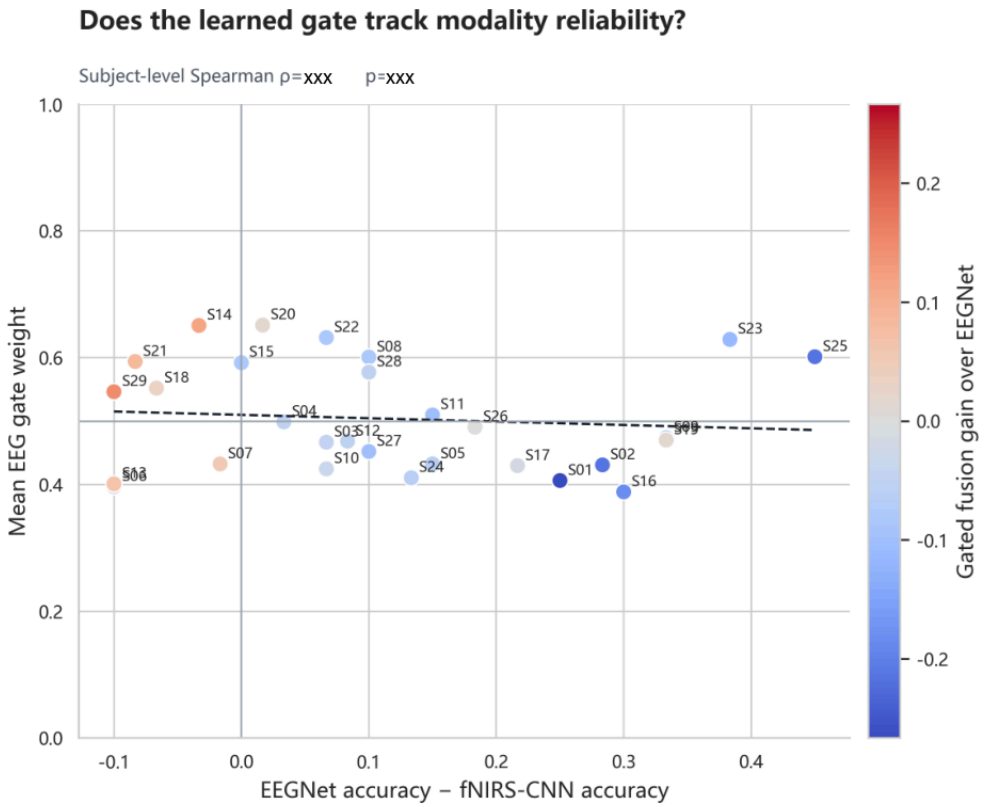


图 7 受试者级单模态性能差与 EEG 门控权重的关系。点颜色表示门控相对 EEGNet 的增益；该图只反映关联，不作因果解释。

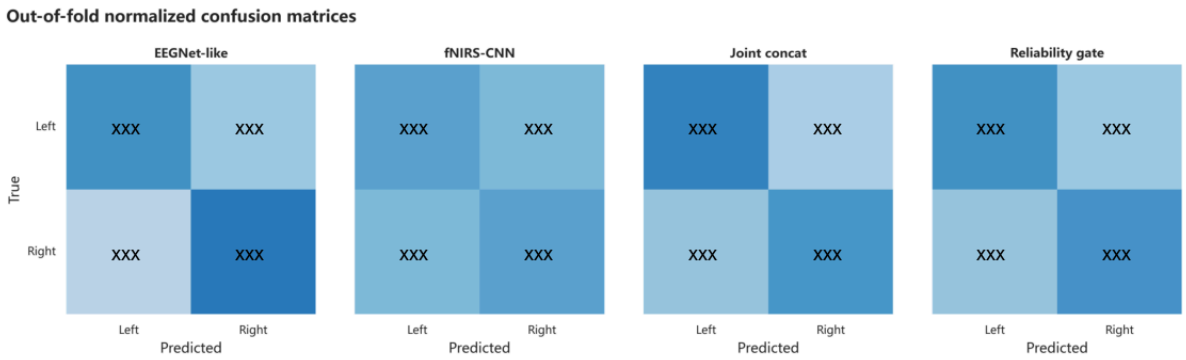


图 8　四类深度模型的 out-of-fold 归一化混淆矩阵。

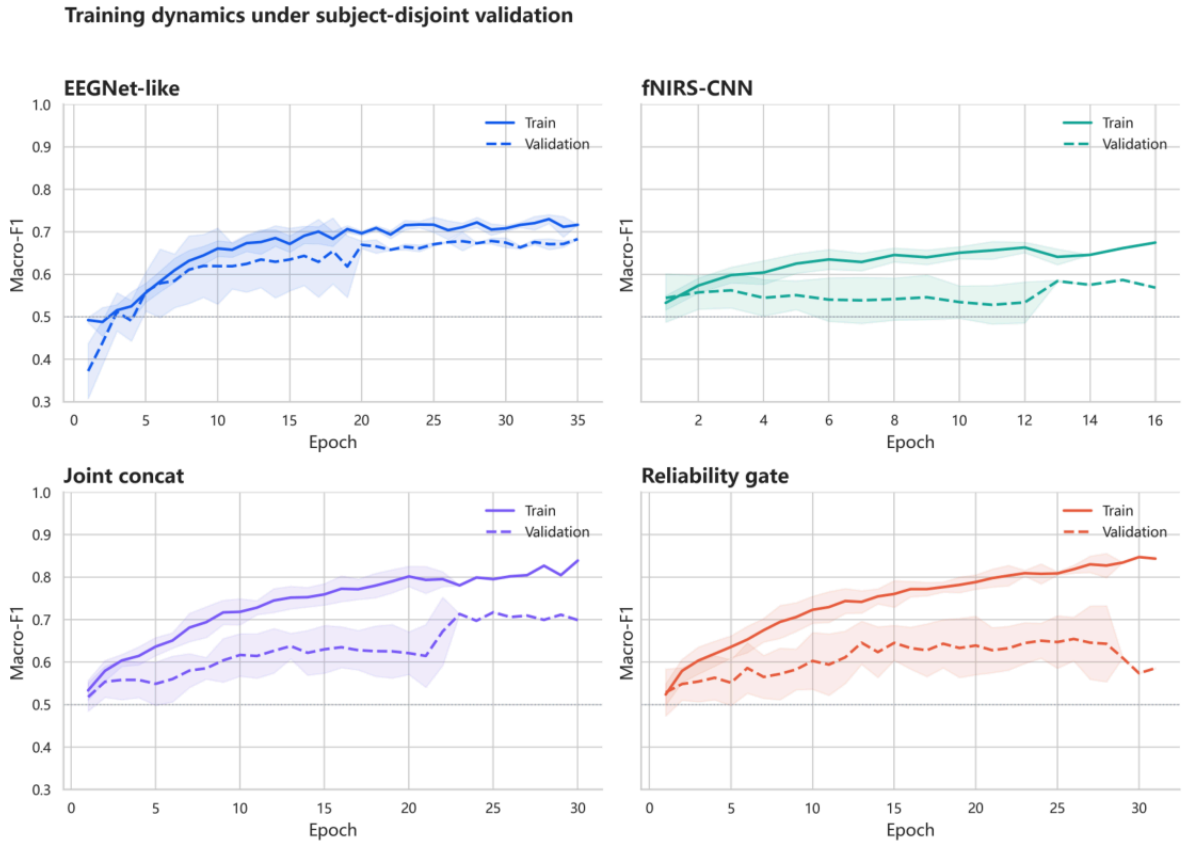


图 9　受试者独立验证下的训练与验证 Macro-F1。实线/虚线分别为训练/验证均值，阴影为折间标准差。

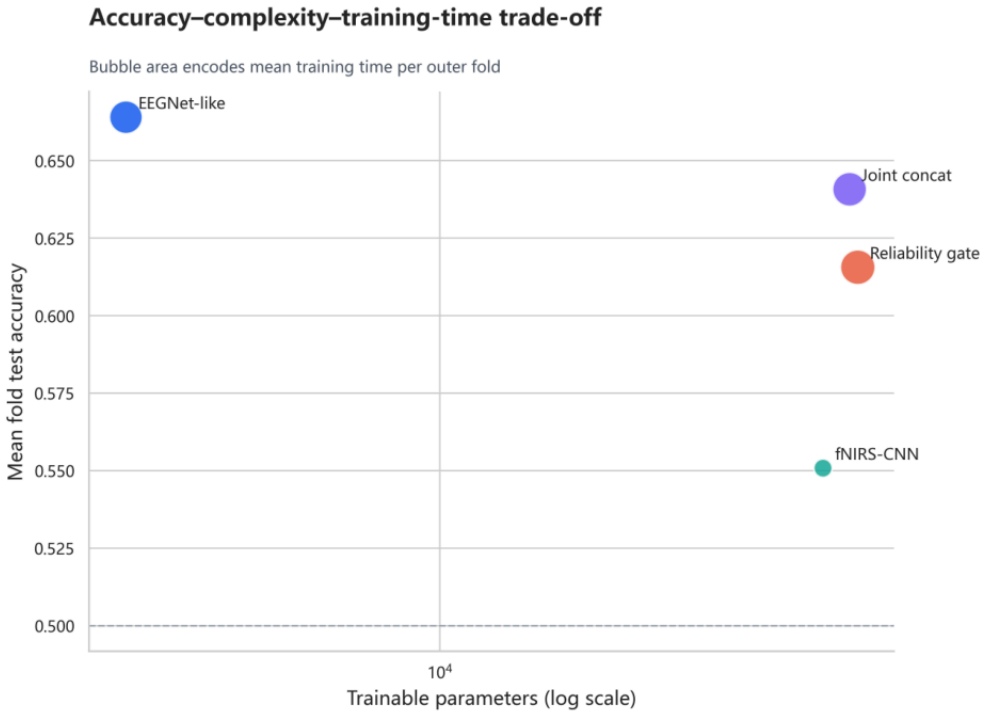


图 10 深度模型的参数量、折均准确率与折均训练时长权衡。

7 讨论

7.1 深度学习带来了什么

第一，EEGNet-like 在严格跨人协议下保持了有意义的识别能力，证明紧凑时空卷积比单纯依赖 CSP 的固定判别方向更有表示弹性。第二，深度模型把实验从手工统计特征扩展到原始时序端到端学习，使模型可以利用 fNIRS 血氧曲线的动态形状，而不只依赖均值与斜率。第三，逐轮曲线、模型参数和检查点构成了真正的深度学习训练证据，而非在经典模型报告中简单加入“神经网络”名词。

7.2 为什么融合没有稳定超过 EEGNet

1. **弱模态拖累。** fNIRS-CNN 的跨人性能显著低于 EEGNet，融合器必须先判断何时忽略 fNIRS，学习难度高于简单拼接；
2. **样本量与参数量不匹配。** xxx 条试次对轻量单分支网络尚可，但对双编码器和融合头仍偏小，联合模型更容易记忆训练受试者；
3. **模态时间尺度不同。** EEG 反映快速神经电活动，fNIRS 反映延迟血氧响应；二者虽按 trial 对齐，但语义时间点并非逐样本同步；
4. **门控缺少质量标签。** 当前门只接受分类损失，没有显式信号质量、不确定性或模态缺失训练，其数值不能天然等同于可靠性；
5. **跨人生理差异。** 头皮、毛发、探头接触、血流动力学和运动想象策略都会改变 fNIRS/EEG 分布，统一全局权重难以适配所有人。

7.3 与文献结果的关系

文献中的早期融合收益与本实验的负/有限收益并不矛盾。Fazli 等主要验证同步模态在受试者内的互补性 [1]；Li 等采用特定 Y 形网络、预处理和评估协议 [10]。本实验的核心约束是测试受试者完全不可见，且所有模型共享同一分组五折。不同协议回答不同问题：受试者内高分说明校准后可用，跨受试者结果则衡量免校准泛化。报告不把这些数字直接混排，也不把“本实验未超过”解释为否定多模态互补的生理事实。

7.4 失败分析的课程价值

高质量深度学习实验不仅要展示最高分，还要说明模型为什么没有达到预期。当前结果把下一步研究问题从“继续加层”收敛到三个可验证方向：显式质量感知、跨人域适应和跨数据集外部验证。这样的负结果比在随机试次划分中获得一个更高但有泄漏风险的数字更接近优秀毕业设计的研究逻辑。

8 从扩展方向到可执行深化实验

8.1 尚未闭合的问题与深化目标

当前实验已经回答“朴素拼接和无监督门控是否稳定有效”，答案是否定的；但它尚未回答三个更精确的问题：**质量信息是否能纠正门控方向、模态损坏训练是否能提高鲁棒性、跨人分布对齐是否能减少最差受试者风险**。因此，深化阶段不以“再尝试若干网络”为目标，而预注册以下研究问题：

RQ1：质量可辨识性。
仅使用训练受试者可计算的信号质量与预测不确定性，能否让门权重随单模态相对优势同方向变化？

RQ2：鲁棒融合。
在随机缺失、伪迹增强和低信噪比条件下，质量感知模型能否比当前门控保持更小的性能退化，同时不牺牲完整模态条件下的准确率？

RQ3：跨人泛化。
在不读取测试受试者标签、主实验也不读取其输入分布的前提下，训练受试者间的表示对齐能否改善受试者级均值、低分位性能和校准度？

深化方向的完成标准不再是“实现了一个新模块”，而是质量指标、门控响应、鲁棒性曲线和跨人统计四类证据同时形成闭环。

8.2 质量感知门控的可实现定义

对第 i 条试次，分别构造 EEG 与 fNIRS 的质量向量

$$\mathbf{q}_i^E = [r_{\text{out}},\, r_{\text{hf}},\, \kappa(\Sigma),\, H(p_E)], \tag{1}$$

$$\mathbf{q}_i^F = [r_{\text{spike}},\, r_{\text{drift}},\, c_{\text{Hb}},\, H(p_F)]. \tag{2}$$

其中，r_{out} 表示基于中位数绝对偏差的 EEG 异常点比例，r_{hf} 表示任务频带外高频能量比，$\kappa(\Sigma)$ 表示通道协方差条件数，$H(p_E)$ 与 $H(p_F)$ 为单模态预测熵；fNIRS 侧的 r_{spike}、r_{drift} 分别衡量一阶差分尖峰和低频漂移，c_{Hb} 描述 HbO/HbR 响应的一致性。所有方向统一变换为“数值越大，质量越高”，且阈值、分位数和标准化统计量只由对应外层折的训练受试者估计。

质量感知门写为

$$g_i = \sigma\big(W_g[\mathbf{z}_i^E, \mathbf{z}_i^F, \mathbf{q}_i^E, \mathbf{q}_i^F] + b_g\big), \qquad \mathbf{z}_i = g_i\mathbf{z}_i^E + (1-g_i)\mathbf{z}_i^F. \tag{3}$$

相比当前只观察表示的门，新门显式获得“为什么应该相信某一模态”的输入。考虑到人工绝对质量标签很难可靠获取，训练目标采用弱监督与扰动一致性：

$$\mathcal{L} = \mathcal{L}_{\text{cls}} + \lambda_r\mathcal{L}_{\text{rank}} + \lambda_m\mathcal{L}_{\text{mod}} + \lambda_c\mathcal{L}_{\text{cal}} + \lambda_d\mathcal{L}_{\text{DG}}. \tag{4}$$

其中，$\mathcal{L}_{\text{rank}}$ 约束门控方向与两模态质量差同号；$\mathcal{L}_{\text{mod}}$ 约束完整输入与模态 Dropout 输入的预测一致性 [7]；$\mathcal{L}_{\text{cal}}$ 遵循“删除或破坏一个模态后，模型置信度不应反而上升”的校准原则 [13]；$\mathcal{L}_{\text{DG}}$ 在训练受试者之间对齐表示的一、二阶统计量。Deep CORAL 提供了协方差对齐的基本实现 [14]，但本文主实验只在训练受试者之间执行对齐，不读取外层测试人的特征分布；若后续允许无标签目标用户校准，则必须单列为“传导式适应”协议，不能与完全归纳式结果混报。

8.3 消融矩阵与公平比较

表 7 将扩展方案拆成单变量递增实验。所有模型继续复用当前五折外层测试、内层受试者验证、随机种子和训练预算；每增加一个组件，都必须与前一行配对比较，避免把架构、数据增强和评估协议同时改变。

表 7 深化阶段预注册消融矩阵

编号	相对当前系统的唯一变化	主要回答	必报附加指标
B0	EEGNet-like 单模态	最强单模态基准	Acc、Macro-F1、ECE
B1	当前拼接融合	无条件联合是否有效	参数量、过拟合间隙
B2	当前可靠性门控	无质量监督的动态权重	门均值、门–优势相关
E1	B2 + 质量向量	质量输入是否有用	质量分布、门响应曲线
E2	E1 + 排序/校准损失	门是否真正学会可靠性	Spearman ρ、ECE
E3	E2 + 模态 Dropout	是否抗缺失与伪迹	性能–扰动强度曲线
E4	E3 + 训练受试者域对齐	是否改善跨人尾部风险	P10、最差人、折间方差
E5	E4 + 外部数据验证	机制是否跨数据集成立	外部 Macro-F1、迁移效率

8.4 统计口径与预注册成功判据

深化实验继续把受试者作为统计单位，并在训练前固定以下判据：

1. **主性能**：相对 EEGNet-like 的受试者级准确率差异同时报告均值、xxx% bootstrap CI、Wilcoxon 检验和胜/平/负；多模型比较使用 Holm 校正。“稳定融合收益”要求差异置信区间下界不低于 0，且至少 xxx/xxx 名受试者不劣；

2. **门控有效性**：门权重与标准化单模态质量优势的 Spearman $\rho \geq$ xxx，并且在定向破坏某一模态时，至少 xxx% 试次的门变化方向正确；

3. **鲁棒性**：分别施加 xxx%、xxx%、xxx% 模态缺失和三个等级的伪迹增强，比较性能–扰动曲线下面积；E3/E4 必须优于 B2，而非只比较完整输入；

4. **泛化与校准**：除均值外报告受试者准确率第 xxx 百分位（P10）、最差受试者、ECE 与负对数似然，防止平均值提升掩盖少数用户显著退化；

5. **计算代价**：在精度相近时优先参数更少、校准时间更短的模型，同时报告参数量、单试次推理时间和训练时长。

这些阈值是研究计划的**判定规则**而非当前实验结果。若新模型只提升总体均值，却不能改善门控方向、扰动鲁棒性或尾部受试者，则只能判定为“更强分类器”，不能判定为“可靠性融合机制”。

8.5 外部验证的边界与两阶段方案

Yi2025 数据包含 xxx 名受试者、8 类单侧上肢多关节运动想象和 xxx 条同步 EEG–fNIRS 试次 [11]。它与 Shin2017A 的左右手二分类并非同一标签空间，因此不能直接进行不加说明的零样本准确率比较。外部验证分为两层：

V1. 机制迁移：在 Yi2025 原生 8 分类任务中重新执行受试者独立评估，检查 E2/E3 是否仍比 B1/B2 具有更好的质量相关、校准和扰动鲁棒性；不同数据集的绝对准确率不直接相减；

V2. 表示迁移：先在 Yi2025 进行无监督时序预训练，再回到 Shin2017A 外层训练折微调，比较使用 xxx%、xxx%、xxx% 标签时的样本效率；外层测试受试者始终不可见。

xxx 年的 fNIRS–EEG 融合综述同样指出，公开数据稀缺、fNIRS 混杂校正不足和融合方法可复现性仍是主要瓶颈 [15]。因此，上述外部验证不仅检验网络性能，也检验预处理、质量度量和统计口径能否跨设备复用。

8.6 课程知识点与产出映射

表 8 深度学习课程知识点在项目中的具体落地

课程知识点	项目实现	可核验证据
卷积表示学习	时间卷积、深度空间卷积、1D 血氧卷积	网络代码、参数量与主结果
优化与正则化	AdamW、Dropout、早停、余弦退火	xxx 行学习曲线与 xxx 个检查点
多模态学习	拼接、门控、质量感知扩展定义	六模型对照、门控相关与消融矩阵
泛化与域偏移	受试者隔离、训练域对齐、外部验证	五折拆分清单与预注册协议
误差与不确定性	逐人差异、置信区间、校准与尾部风险	逐试次预测、ECE/P10 扩展指标
复现工程	固定种子、缓存、检查点、机器验收	脚本、CSV、JSON 与验收报告

9 局限性、伦理与有效性威胁

9.1 局限性

- 只使用一个 xxx 人公开数据集，尚不能代表临床或消费级 BCI 人群；
- 本轮为轻量模型公平比较，未进行大规模贝叶斯超参数搜索；
- 门控为标量样本级权重，尚未建模通道级质量与时变不确定性；
- 未在完全不同采集设备和任务标签上进行外部验证；
- 配对检验为探索性分析，未做多重比较校正；
- 第 8 节属于预注册式深化方案，尚未产生新的实验结果，不与第 6 节已完成的主实验结论混合陈述。

9.2 有效性威胁控制

内部有效性方面，所有监督预处理、归一化和早停均限制在训练/验证受试者内；统计有效性方面，以受试者而非试次作为 bootstrap 单位；构念有效性方面，门控权重只称为模型权重，不直接等同于生理可靠性；外部有效性方面，明确限制结论在 Shin2017A 左右手运动想象任务内。

9.3 伦理说明

本项目使用公开去标识数据，不尝试恢复参与者身份。脑信号具有潜在隐私属性，后续部署应落实知情同意、数据最小化和模型用途限制。分类结果仅用于课程研究，不构成医疗诊断或康复决策。

A 复现实验命令

```
# 1. 准备 xxx 名受试者的同步 EEG-fNIRS 缓存
.\.venv\Scripts\python.exe scripts\09_prepare_shin2017_eeg_fnirs.py `
  --subjects 1-xxx --accept-license

# 2. 运行经典多模态基线
.\.venv\Scripts\python.exe scripts\10_run_eeg_fnirs_fusion.py `
  --subjects 1-xxx

# 3. 运行受试者独立深度学习实验
.\.venv\Scripts\python.exe scripts\13_run_deep_eeg_fnirs.py `
  --max-epochs xxx --min-epochs xxx --patience 8 `
  --batch-size xxx --bootstrap xxx   --device cpu

# 4. 生成深度实验图表
.\.venv\Scripts\python.exe scripts\14_plot_deep_eeg_fnirs_results.py

# 5. 验收数据、拆分、预测、检查点和图表
.\.venv\Scripts\python.exe scripts\15_validate_deep_eeg_fnirs_outputs.py

# 6. 生成报告与 PPT 共用的真实结果资产
.\.venv\Scripts\python.exe scripts\16_prepare_course_deliverable_assets.py
```

B 核心产物索引

- 实验清单：outputs/eeg_fnirs_deep/tables/deep_experiment_manifest.json
- 模型汇总：outputs/eeg_fnirs_deep/tables/deep_model_summary.csv
- 逐试次预测：outputs/eeg_fnirs_deep/tables/deep_oof_predictions.csv
- 受试者结果：outputs/eeg_fnirs_deep/tables/deep_subject_results.csv
- 学习曲线：outputs/eeg_fnirs_deep/tables/deep_training_curves.csv
- 配对比较：outputs/eeg_fnirs_deep/tables/deep_paired_comparisons.csv
- 机器验收：outputs/eeg_fnirs_deep/tables/deep_validation_report.json
- 模型检查点：outputs/eeg_fnirs_deep/models/
- 复现指南：docs/deep_learning_experiment_guide.md

C 报告证据口径

报告正文中的经典实验数字来自 outputs/eeg_fnirs/tables/eeg_fnirs_model_summary.csv；深度实验数字来自 outputs/eeg_fnirs_deep/tables/deep_model_summary.csv 与 deep_paired_

comparisons.csv。LaTeX 宏和表格由脚本自动生成，避免人工复制导致报告、CSV 与 PPT 不一致。所有图均由原始汇总表重新绘制，未进行手工编辑。

参考文献

[1] S. Fazli, J. Mehnert, J. Steinbrink, G. Curio, A. Villringer, K.-R. Müller, and B. Blankertz, "Enhanced performance by a hybrid nirs–eeg brain computer interface," *NeuroImage*, vol. 59, no. 1, pp. 519–529, 2012.

[2] J. Shin, A. von Lühmann, B. Blankertz, D.-W. Kim, J. Jeong, H.-J. Hwang, and K.-R. Müller, "Open access dataset for eeg+nirs single-trial classification," *IEEE Transactions on Neural Systems and Rehabilitation Engineering*, vol. 25, no. 10, pp. 1735–1745, 2017.

[3] Y. Roy, H. Banville, I. Albuquerque, A. Gramfort, T. H. Falk, and J. Faubert, "Deep learning-based electroencephalography analysis: A systematic review," *Journal of Neural Engineering*, vol. 16, no. 5, p. 051001, 2019.

[4] V. J. Lawhern, A. J. Solon, N. R. Waytowich, S. M. Gordon, C. P. Hung, and B. J. Lance, "Eegnet: A compact convolutional neural network for eeg-based brain-computer interfaces," *Journal of Neural Engineering*, vol. 15, no. 5, 2018.

[5] T. Baltrušaitis, C. Ahuja, and L.-P. Morency, "Multimodal machine learning: A survey and taxonomy," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 41, no. 2, pp. 423–443, 2019.

[6] J. Arevalo, T. Solorio, M. Montes-y Gómez, and F. A. González, "Gated multimodal units for information fusion," 2017.

[7] N. Neverova, C. Wolf, G. W. Taylor, and F. Nebout, "Moddrop: Adaptive multi-modal gesture recognition," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 38, no. 8, pp. 1692–1706, 2016.

[8] Q. Zhang, H. Wu, C. Zhang, Q. Hu, H. Fu, J. T. Zhou, and X. Peng, "Provable dynamic fusion for low-quality multimodal data," in *Proceedings of the 40th International Conference on Machine Learning*, vol. 202. PMLR, 2023, pp. 41 753–41 769. [Online]. Available: https://proceedings.mlr.press/v202/zhang23ar.html

[9] Z. Gao, X. Jiang, X. Xu, F. Shen, Y. Li, and H. T. Shen, "Embracing unimodal aleatoric uncertainty for robust multimodal fusion," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2024, pp. 26 876–26 885. [Online]. Available: https://openaccess.thecvf.com/content/CVPR2024/html/Gao_Embracing_Unimodal_Aleatoric_Uncertainty_for_Robust_Multimodal_Fusion_CVPR_2024_paper.html

[10] Y. Li, X. Zhang, and D. Ming, "Early-stage fusion of eeg and fnirs improves classification of motor imagery," *Frontiers in Neuroscience*, vol. 16, p. 1062889, 2023.

[11] W. Yi, J. Chen, D. Wang, X. Hu, M. Xu, F. Li, S. Wu, and J. Qian, "A multi-modal dataset of electroencephalography and functional near-infrared spectroscopy recordings for motor imagery of multi-types of joints from unilateral upper limb," *Scientific Data*, vol. 12, p. 953, 2025.

[12] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations*, 2019. [Online]. Available: https://openreview.net/forum?id=Bkg6RiCqY7

[13] H. Ma, Q. Zhang, C. Zhang, B. Wu, H. Fu, J. T. Zhou, and Q. Hu, "Calibrating multimodal learning," in *Proceedings of the 40th International Conference on Machine Learning*, vol. 202. PMLR, 2023, pp. 23 429–23 450. [Online]. Available: https://proceedings.mlr.press/v202/ma23i.html

[14] B. Sun and K. Saenko, "Deep coral: Correlation alignment for deep domain adaptation," in *Computer Vision – ECCV 2016 Workshops*, 2016, pp. 443–450.

[15] T. Codina, B. Blankertz, and A. von Lühmann, "Multimodal fnirs–eeg sensor fusion: Review of data-driven methods and perspective for naturalistic brain imaging," *Imaging Neuroscience*, vol. 3, p. IMAG.a.974, 2025.